

Vizsgajegyzet: Regularizáció

ML-005 Lecture 7 | Stanford University

2025. június 14., 16:23 CEST

Forrás

Diasor („regularizáció.pptx”) és ML-005 Lecture 7 eladás

1. Bevezetés

A túlillesztés (overfitting) a gépi tanulás egyik gyakori problémája, amikor a modell túl jól illeszkedik a tanító adatokra, de nem általánosít megfelelően új, korábban nem látott adatokra. Ez különösen akkor fordul el, ha a modell túl sok jellemzt használ, vagy túl bonyolult hipotézist tanul meg. A regularizáció egy technika, amely csökkenti a túlillesztést azáltal, hogy korlátozza a modell paramétereinek nagyságát, így egyszerűbb és robusztusabb modellt eredményez. A regularizáció alkalmazható mind lineáris, mind logisztikus regresszióra.

- **Cél:** A túlillesztés csökkentése, hogy a modell jobban általánosítson.
- **Példák:**
 - Lineáris regresszió: Lakásárak elrejelzése túl sok polinomiális jellemzvel.
 - Logisztikus regresszió: Osztályozási problémák, ahol a döntési határ túl komplex.
- **Kontextus:** A regularizáció különösen hasznos, ha sok jellemz van, amelyek mindegyike kissé hozzájárul az elrejelzéshez.

2. Túlillesztés Problémája

A túlillesztés akkor következik be, amikor a modell a tanító adatok zaját is megtanulja, így a költségfüggvény ($J(\theta)$) a tanító adathalmazon nagyon kicsi, de az új adatokon rossz a teljesítmény.

- **Példa: Lineáris regresszió:**
 - Egyszeres modell: $h_{\theta}(x) = \theta_0 + \theta_1 x$ (alulillesztés, nagy hiba).
 - Közepes komplexitás: $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2$ (jó illeszkedés).
 - Túl komplex: $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$ (túlillesztés, a tanító adatokra tökéletes, de új adatokra rossz).

- **Példa: Logisztikus regresszió:** Túl sok jellemz használata komplex döntési határt eredményez, amely nem általánosít jól.
- **Tulajdonságok:**
 - A tanító adatokon: $J(\theta) \approx 0$.
 - Új adatokon: Nagy predikciós hiba.

3. Túlillesztés Kezelése

A túlillesztés csökkentésére két fő megközelítés létezik: a jellemzők számának csökkentése és a regularizáció.

- **1. Jellemzők számának csökkentése:**
 - Kézi kiválasztás: Pl. házáraknál csak a méretet (x_1) és a hálósobák számát (x_2) tartjuk meg, elhagyva pl. a konyha méretét (x_6).
 - Modellválasztó algoritmusok: Automatikus jellemzőkiválasztás (későbbi előadások témája).
- **2. Regularizáció:**
 - Az összes jellemző megtartása, de a paraméterek (θ_j) nagyságának csökkentése.
 - Elny: Jól működik, ha sok jellemző van, és mindegyik kis mértékben hozzájárul az előrejelzéshez.
 - Példa: Házáraknál 100 jellemző ($x_1, \dots, x_{100}$), pl. méret, hálósobák száma, szomszédság átlagjövedelme.

4. Regularizáció Intuíciója

A regularizáció a paraméterek kis értékeit részesíti előnyben, így egyszerűbb hipotézist eredményez, amely kevésbé hajlamos a túlillesztésre.

- **Példa:** Lakások elrejelzése:
 - Modell: $h_\theta(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$.
 - Regularizáció nélkül: θ_3, θ_4 nagy lehet, komplex görbét adva.
 - Regularizációval: θ_3, θ_4 kicsi, közelítve egy másodfokú modellhez: $h_\theta(x) \approx \theta_0 + \theta_1 x + \theta_2 x^2$.
- **Hatás:** Egyszerűbb modell, kevesebb túlillesztés.

5. Regularizált Lineáris Regresszió

A regularizáció a költségfüggvényhez egy büntet tagot ad, amely a paraméterek nagyságát korlátozza.

- **Költségfüggvény:**

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

ahol:

- $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$.
- λ : Regularizációs paraméter, amely szabályozza a büntetés erősségét.
- $\sum_{j=1}^n \theta_j^2$: Bünteti a nagy paramétereket (kivéve θ_0 -t, hogy ne befolyásolja az eltolást).

- **Regularizációs paraméter (λ):**

- Ha λ túl nagy (pl. $\lambda = 10^{10}$): A paraméterek ($\theta_1, \dots, \theta_n$) közel nullára csökkennek, alulillesztést okozva.
- Ha λ túl kicsi: Kevés regularizáció, túlillesztés maradhat.

- **Cél:** $\min_{\theta} J(\theta)$.

5.1. Gradiens Ereszkedés

A gradiens ereszkedés a regularizált költségfüggvény minimalizálására szolgál.

- **Frissítési szabály:**

$$\begin{aligned} \theta_0 &:= \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)} \\ \theta_j &:= \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right], \quad j = 1, \dots, n \end{aligned}$$

Alternatív forma:

$$\theta_j := \theta_j \left(1 - \alpha \frac{\lambda}{m} \right) - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}, \quad j = 1, \dots, n$$

- **Megjegyzés:** θ_0 nem regularizálódik, mert $x_0 = 1$, és az eltolás nem befolyásolja a modell komplexitását.
- **Példa kód (Python):**

```

import numpy as np
for iter in range(max_iter):
    predictions = np.dot(X, theta)
    errors = predictions - y
    gradients = (1/m) * np.dot(X.T, errors)
    gradients[1:] += (lambda_/m) * theta[1:] # Regularizáció theta_1-től
    theta[0] -= alpha * gradients[0] # theta_0 külön
    theta[1:] -= alpha * gradients[1:]
    J = (1/(2*m)) * (np.sum(errors**2) + lambda_ * np.sum(theta[1:]**2))
    if abs(J_old - J) < epsilon:
        break

```

5.2. Normál Egyenlet

A normál egyenlet analitikus megoldást nyújt a regularizált költségfüggvény minimalizálására.

- **Képlet:**

$$\theta = \left(X^T X + \lambda \begin{bmatrix} 0 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \right)^{-1} X^T y$$

ahol X az $m \times (n+1)$ mátrix, a hozzáadott mátrix $(n+1) \times (n+1)$ méret, és csak az $1, \dots, n$ indexek mentén tartalmaz 1-eket (θ_0 nem regularizálódik).

- **Elny:** Nem iteratív, nem kell tanulási rátát (α) választani.
- **Hátrány:** Lassú nagy n -re ($O(n^3)$).
- **Nem invertálhatóság:** Ha $m \leq n$, vagy redundáns jellemzők vannak, a regularizáció ($\lambda > 0$) biztosítja, hogy $X^T X + \lambda I$ invertálható legyen.

6. Regularizált Logisztikus Regresszió

A logisztikus regresszió regularizálása hasonlóan működik, a túlillesztés csökkentésére a döntési határok egyszersítésével.

- **Költségfüggvény:**

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-y^{(i)} \log(h_{\theta}(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

ahol $h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}}$, és θ_0 nem regularizálódik.

- **Gradiens ereszkedés:**

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right], \quad j = 1, \dots, n$$

- **Példa:** Osztályozási probléma sok jellemzvel (pl. $x_1, x_2, \dots, x_{100}$), ahol a regularizáció egyszerűbb döntési határt biztosít.

7. Fejlett Optimalizálás

A gradiens ereszkedés mellett fejlettebb algoritmusok is használhatók a regularizált költségfüggvény minimalizálására.

- **Cél:** $J(\theta)$ és $\frac{\partial}{\partial \theta_j} J(\theta)$ kiszámítása minden j -re, majd $\min_{\theta} J(\theta)$ megtalálása.
- **Példa** (MATLAB/Octave):

```
function [jVal, gradient] = costFunction(theta, X, y, lambda)
    m = length(y);
    h = sigmoid(X * theta);
    jVal = (1/m) * sum(-y .* log(h) - (1-y) .* log(1-h)) + ...
           (lambda/(2*m)) * sum(theta(2:end).^2);
    gradient = (1/m) * (X' * (h - y));
    gradient(2:end) += (lambda/m) * theta(2:end);
end
options = optimset('GradObj', 'on', 'MaxIter', 100);
initialTheta = zeros(n+1, 1);
[optTheta, functionVal, exitFlag] = fminunc(@(t)costFunction(t, X, y, lambda), .
                                           initialTheta, options);
```

- **Elnyök:** Gyorsabb konvergencia, automatikus lépésméret.

8. Példa Alkalmazás

- **Probléma:** Lakásárak előrejelzése sok jellemzvel.
- **Adatok:** $\{(x^{(i)}, y^{(i)})\}$, pl. $x^{(i)} = [1, \text{méret}, \text{hálószobák}, \text{emeletek}, \text{kor}]^T$.
- **Folyamat:**
 1. Inicializálás: $\theta = [0, 0, 0, 0, 0]^T$, $\alpha = 0.01$, $\lambda = 1$.
 2. Jellemzk skálázása: Pl. méret: $x_1 := \frac{\text{méret} - 1000}{2000}$.
 3. Gradiens ereszkedés vagy normál egyenlet futtatása a regularizált $J(\theta)$ minimalizálására.

4. Eredmény: Pl. $\theta = [50, 0.1, 20, 10, -5]^T$.

- **Predikció:** Új ház: $x = [1, 1800, 4, 2, 35]^T$:

$$h_{\theta}(x) = 50 + 0.1 \cdot 1800 + 20 \cdot 4 + 10 \cdot 2 - 5 \cdot 35 = 155 \text{ (ezer dollár)}$$

9. Kulcsformulák

- **Regularizált lineáris regresszió költségfüggvénye:**

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

- **Gradiens ereszkedés (lineáris regresszió):**

$$\begin{aligned} \theta_0 &:= \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)} \\ \theta_j &:= \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right], \quad j = 1, \dots, n \end{aligned}$$

- **Normál egyenlet:**

$$\theta = \left(X^T X + \lambda \begin{bmatrix} 0 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix} \right)^{-1} X^T y$$

- **Regularizált logisztikus regresszió költségfüggvénye:**

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-y^{(i)} \log(h_{\theta}(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$