

Vizsgajegyzet: Lineáris Regresszió Egytváltozós Esetben

ML-005 Lecture 2 | Stanford University | Andrew Ng

2025. június 14., 15:52 CEST

Forrás

Diasor („lineárisregresszió 1.pptx”) és PDF („lineáris regresszió.pdf”)

1. Bevezetés

A lineáris regresszió egy felügyelt tanulási módszer, amelynek célja egy folytonos kimeneti változó (y) elrejelzése egy vagy több bemeneti változó (x) alapján. Az egytváltozós lineáris regresszió esetében egyetlen bemenetet használunk, amely egy egyszer, de hatékony megközelítés a gépi tanulásban.

- **Regresszió definíciója:** A regresszió megbecsüli a kapcsolatot a függő változó (y , amit előre akarunk jelezni) és egy független változó (x , magyarázó változó) között. A modell paraméterei leírják, hogyan befolyásolja x az y -t, így segítve az adatok közötti összefüggések megértését és elrejelzését.
- **Cél:** Folytonos érték kimenet (y) elrejelzése egy bemenet (x) alapján, például egy valós szám predikciója minden mintapontra.
- **Példák:**
 - Házárak elrejelzése a ház mérete alapján (pl. Portland, OR adathalmaz).
 - Cég profitjának becslése az ügyfelek száma alapján.
- **Tanulási típus:** Felügyelt tanulás, címkézett adatokkal: $(x^{(i)}, y^{(i)})$, ahol minden adatpont egy bemenet-kimenet párt tartalmaz.
- **Kontextus:** Egytváltozós lineáris regresszió, ahol csak egy bemenet (x) van, és a cél egy lineáris kapcsolat modellezése.

2. Modell Reprezentáció

Az egytváltozós lineáris regresszió célja egy lineáris függvény illesztése az adatokra, amely a bemenet (x) alapján elrejelzi a kimenetet (y). Ez a folyamat egy tanuló algoritmus segítségével történik, amely a tanító adatok alapján meghatározza a modell paramétereit.

- **Adathalmaz:**

- Tanító példák: $(x^{(i)}, y^{(i)})$, ahol $i = 1, 2, \dots, m$.
- m : Tanító példák száma.
- x : Bemeneti változó (pl. ház mérete lábban²).
- y : Kimeneti változó (pl. ház ára ezer dollárban).

- **Példa adathalmaz** (Portland, OR):

Ház mérete (x , lábban ²)	Ár (y , ezer dollárban)
2104	460
1416	232
1534	315
852	178
...	...

1. táblázat. Példa adathalmaz házáruk elrejelzéséhez.

- **Jelölések:**

- m : Tanító adatok száma.
- x : Bemeneti adat (jellemz, pl. ház mérete).
- y : Kimeneti adat (célváltozó, pl. ház ára).

- **Hipotézis függvény:**

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

- θ_0 : Tengelymetszet (bias), a függvény y -tengelyen való eltolása.
- θ_1 : Meredekség (slope), amely a bemenet hatását írja le az y -ra.
- Példa: Ha $\theta_0 = 50$, $\theta_1 = 2$, és $x = 100$ (nm), akkor:

$$h_{\theta}(100) = 50 + 2 \cdot 100 = 250 \text{ (ezer dollár)}$$

- **Tanuló algoritmus:** A cél olyan θ_0 és θ_1 paraméterek megtalálása, amelyekkel $h_{\theta}(x)$ a lehet legközelebb van az y -hoz minden tanító példára. Ez egy optimalizációs probléma, amelyet a költségfüggvény minimalizálásával oldunk meg.

3. Költségfüggvény

A költségfüggvény (cost function) méri, hogy a hipotézis függvény mennyire illeszkedik az adatokra, azaz mennyire pontosak az elrejelzések.

- **Definíció:**

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

- Négyzetes hiba: $(h_\theta(x^{(i)}) - y^{(i)})^2$, amely az előrejelzés és a tényleges érték közötti eltérést méri.
- Átlagolás: $\frac{1}{m}$, hogy az adatpontok számától független legyen.
- $\frac{1}{2}$: Matematikai egyszersítés a deriválás során.
- **Hipotézis függvény:**

$$h_\theta(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$
- **Cél:** $J(\theta_0, \theta_1)$ minimalizálása a legjobb θ_0, θ_1 értékek megtalálásával, hogy a modell a lehet legpontosabb legyen.
- **Példa számítás:**
 - Adatok: $(x^{(1)}, y^{(1)}) = (1, 2)$, $(x^{(2)}, y^{(2)}) = (2, 4)$, $m = 2$.
 - Hipotézis: $h_\theta(x) = 0 + 1 \cdot x$.
 - Hibák:
 - * $h_\theta(1) = 1$, hiba: $1 - 2 = -1$, $(1 - 2)^2 = 1$.
 - * $h_\theta(2) = 2$, hiba: $2 - 4 = -2$, $(2 - 4)^2 = 4$.
 - Költség: $J = \frac{1}{2}(1 + 4) = 1.25$.

4. Költségfüggvény Vizualizációja

A költségfüggvény vizualizációja segít megérteni, hogyan változik a hiba a paraméterek függvényében.

- **1D eset** ($\theta_0 = 0$): $J(\theta_1)$ egy parabola, amelynek minimuma a legjobb θ_1 értéket adja. Ez azt mutatja, hogy a meredekség (θ_1) hogyan befolyásolja az illeszkedést.
- **2D eset** (θ_0, θ_1): $J(\theta_0, \theta_1)$ egy 3D tál alakú felület, amely konvex, így egyetlen globális minimuma van.
- **Kontúr diagram:** Ellipszisek mutatják az azonos J -értékeket, segítve az optimalizációs folyamat szemléltetését.
- **Példa vizualizáció:** A diasor szerint, ha $\theta_0 = -1$, $\theta_1 = 0$, a modell nem illeszkedik jól, míg $\theta_0 = 0$, $\theta_1 = 0.5$ jobb illeszkedést ad (lásd a diasor 8. oldalát).

5. Gradiens Ereszkedés

A gradiens ereszkedés (gradient descent) egy iteratív algoritmus, amely a költségfüggvény ($J(\theta_0, \theta_1)$) minimalizálására szolgál azáltal, hogy lépésről lépésre frissíti a paramétereket.

- **Frissítési szabály** ($j = 0, 1$):

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

- **Parciális deriváltak:**

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

- **Tanulási ráta (α):** A lépésméret, amely meghatározza, hogy mekkora lépéseket tesz az algoritmus a minimum felé.
 - Túl nagy α : Divergencia, az algoritmus túllépheti a minimumot, vagy akár divergálhat (lásd a diasor 35. oldalát).
 - Túl kicsi α : Lassú konvergencia, ami idigényes lehet.
- **Algoritmus** (egyidej frissítés):

$$\text{ismételd, amíg konvergál} \left\{ \begin{array}{l} \text{temp}_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \\ \text{temp}_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)} \\ \theta_0 := \text{temp}_0 \\ \theta_1 := \text{temp}_1 \end{array} \right\}$$

- **Konvergencia:** A gradiens ereszkedés automatikusan kisebb lépéseket tesz a minimum közelében, mivel a gradiens csökken, így nincs szükség α idbeli csökkentésére (lásd a diasor 37. oldalát).
- **Batch Gradient Descent:** A gradiens ereszkedés minden lépése az összes tanító mintát figyelembe veszi („batch”), biztosítva a stabil konvergenciát (lásd a diasor 54. oldalát).

6. Gyakorlati Szempontok

- **Jellemz skálázás:** A bemeneteket (x) érdemes skálázni (pl. $[0, 1]$ intervallumra) a gyorsabb konvergencia érdekében, mivel ez csökkenti a költségfüggvény felületének torzulását.
- **Tanulási ráta:** Próbálj ki különböző értékeket: $\alpha = 0.001, 0.01, 0.1$, és figyeld a konvergencia viselkedését.
- **Konvergencia teszt:** Ábrázold $J(\theta_0, \theta_1)$ -t az iterációk függvényében, hogy ellenrizd, csökken-e a költségfüggvény.
- **Hibakeresés:** Numerikus deriválás használata a gradiens ellenrzésére:

$$\frac{J(\theta_j + \epsilon) - J(\theta_j - \epsilon)}{2\epsilon}$$

- **Példa kód** (Python, a diasor és PDF alapján):

```
for iter in range(max_iter):
    predictions = theta_0 + theta_1 * x
    errors = predictions - y
    theta_0 -= alpha * (1 / m) * sum(errors)
    theta_1 -= alpha * (1 / m) * sum(errors * x)
    J = (1 / (2 * m)) * sum(errors ** 2)
    if abs(J_old - J) < epsilon:
        break
```

7. Alternatív Optimalizáció

- **Normál egyenlet:**

$$\theta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- **Elny:** Nem iteratív, közvetlen megoldást ad, így nincs szükség tanulási rátára vagy iterációkra.
- **Hátrány:** Lassú nagy m -re, mivel a mátrix inverzió számítási költsége jelents (pl. $\mathcal{O}(n^3)$).

8. Példa Alkalmazás

- **Probléma:** Házárak elrejelzése Portland, OR adathalmaz alapján.
- **Adatok:** (100, 200), (150, 300), (200, 400).
- **Folyamat:**
 1. Inicializálás: $\theta_0 = 0$, $\theta_1 = 0$, $\alpha = 0.01$.
 2. Skálázás: $x' = \frac{x-100}{100}$, hogy a bemenetek $[0, 1]$ -re essenek.
 3. Gradiens ereszkedés futtatása az iteratív paraméterfrissítéssel.
 4. Eredmény: Például $h_\theta(x) = 50 + 2x$.
- **Predikció:** $x = 175$ nm:

$$h_\theta(175) = 50 + 2 \cdot 175 = 400 \text{ (ezer dollár)}$$

9. Kulcsformulák

- **Hipotézis:**

$$h_\theta(x) = \theta_0 + \theta_1 x$$

- **Költségfüggvény:**

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)})^2$$

- **Gradiens ereszkedés:**

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

10. A Kulcsformulák Közötti Különbség

- **Hipotézis függvény** ($h_{\theta}(x)$): Ez a modell, amely elrejelzi a kimenetet (y) az adott bemenet (x) alapján, a paraméterek (θ_0 és θ_1) segítségével. Formája:

$$h_{\theta}(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$

- **Költségfüggvény** ($J(\theta_0, \theta_1)$): Ez a mérszám, amely azt mutatja, hogy mennyire tér el a hipotézis a tényleges adatoktól. A cél a minimumának megtalálása:

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

- **Gradiens ereszkedés:** Algoritmus a költségfüggvény minimalizálására az θ_0 és θ_1 paraméterek iteratív frissítésével:

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$