

Vizsgajegyzet: Klaszterezés a Gépi Tanulásban

ML-005 Eladás 13 | Stanford University | Andrew Ng

Ez a jegyzet a Stanford Egyetem ML-005 kurzusának 13. előadása és a hozzá tartozó `klaszterezés.pptx` diáor alapján készült. Részletesen tárgyalja a klaszterezés fogalmait, a K-means algoritmust, annak optimalizálását, alkalmazásait és korlátait. A jegyzet magyar nyelven íródott, strukturált formában, és ideális vizsgára való felkészüléshez.

1. Bevezetés a klaszterezésbe

A klaszterezés egy gépi tanulási technika, amely az adatokat csoportokba (klaszterekbe) rendezi úgy, hogy az azonos csoportba tartozó adatok hasonlóbbak egymáshoz, mint a különböző csoportokba tartozók. Ez egy felügyelet nélküli tanulási módszer, amely nem használ előre megadott címkéket vagy célváltozókat, hanem az adatok belső szerkezetét próbálja feltárni. A klaszterezés célja az adatok természetes csoportosulásának azonosítása, például ügyfélsegmentáció, szociális hálózati elemzés vagy csillagászati adatfeldolgozás céljából.

A klaszterezés különösen hasznos, amikor strukturálatlan adatokat szeretnénk kategorizálni vagy elemezni anélkül, hogy előre meghatározott osztályokat kapnánk. Például egy online áruház használhatja a klaszterezést ügyfelek vásárlási szokásainak csoportosítására, hogy célzott marketingkampányokat indíthasson.

2. A K-means algoritmus

A K-means algoritmus a klaszterezés egyik legelterjedtebb módszere, amely az adatokat K számú klaszterbe osztja iteratív módon, minimalizálva az adatpontok és a klaszter-centroidok közötti távolságot.

2.1. Bemenet

- **Klaszterek száma (K):** Az előre megadott klaszterek száma.
- **Tanító adat:** Adathalmaz $\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}$, ahol minden $x^{(i)} \in \mathbb{R}^n$ egy n -dimenziós adatpont. A konvenció szerint az $x_0 = 1$ bias tagot elhagyjuk.

2.2. Algoritmus lépései

A K-means algoritmus iteratív folyamat, amely a következő lépésekből áll:

1. **Véletlenszerű inicializálás:** Válasszunk véletlenszerűen K klaszter-középpontot ($\mu_1, \mu_2, \dots, \mu_K \in \mathbb{R}^n$). Alternatívaként választhatunk K tanító példát inicializációs centroidként. Fontos, hogy $K < m$, vagyis a klaszterek száma kisebb legyen, mint az adatpontok száma.
2. **Klaszter hozzárendelés:** Minden adatpont $x^{(i)}$ (ahol $i = 1, \dots, m$) esetén rendeljük hozzá a legközelebbi centroidhoz:

$$c^{(i)} = \arg \min_k \|x^{(i)} - \mu_k\|^2,$$

ahol $\|\cdot\|^2$ az euklideszi távolság négyzete, és $c^{(i)}$ az i -edik adatpont klaszterindexe (1-tl K -ig).

3. **Centroid frissítés:** Minden klaszter k (ahol $k = 1, \dots, K$) esetén frissítsük a centroidot μ_k -et az ahhoz rendelt adatpontok átlagaként:

$$\mu_k = \frac{1}{|C_k|} \sum_{i:c^{(i)}=k} x^{(i)},$$

ahol $|C_k|$ az k -edik klaszterhez tartozó adatpontok száma.

4. **Konvergencia ellenrzése:** Ismételjük a 2. és 3. lépést, amíg a hozzárendelések ($c^{(i)}$) és a centroidok (μ_k) nem változnak jelentősen, vagy el nem érjük a maximális iterációs számot.

2.3. Költségfüggvény

A K-means algoritmus célja a következő költségfüggvény (torzítási függvény) minimalizálása:

$$J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K) = \frac{1}{m} \sum_{i=1}^m \|x^{(i)} - \mu_{c^{(i)}}\|^2$$

- $c^{(i)}$: Az i -edik adatpont klaszterindexe.
- $\mu_{c^{(i)}}$: Az i -edik adatpont klaszterének centroidja.
- A cél: Minimalizálni J -t a hozzárendelések és centroidok optimalizálásával.

Ez a függvény az adatpontok és a hozzájuk rendelt klaszter-középpontok közötti átlagos négyzetelt távolságot méri, ami a klaszterek kompaktságát és elválasztottságát tükrözi.

2.4. Pé esettanulmány

Tegyük fel, hogy egy kiskereskedelmi cég ügyfelek vásárlási szokásait szeretné csoportosítani kétdimenziós adatok alapján (pl. éves kiadás és vásárlások száma). Ha $K = 3$, az algoritmus:

- Véletlenszeren választ három centroidot.
- Minden ügyfelet a legközelebbi centroidhoz rendel.
- Frissíti a centroidokat az új csoportok átlaga alapján.
- Ismétli, amíg a csoportok stabilak nem lesznek.

Ez a folyamat például azonosíthatja a gyakori vásárlók, alkalmi vásárlók és ritka vásárlók csoportjait.

3. Lokális optimumok kezelése

A K-means algoritmus érzékeny az inicializációra, és lokális optimumokba ragadhat, ami nem garantálja a globális optimum elérését. A probléma kezelésére a következő módszert alkalmazzuk:

- **Többszöri futtatás:** Futtassuk az algoritmust többször (pl. 100-szor) különböző véletlenszer inicializációkkal.
- **Költségfüggvény összehasonlítása:** Számítsuk ki a költségfüggvényt (J) minden futtatásra, és válasszuk ki azt a klaszterezést, amely a legkisebb J értéket adja.

Ez növeli az esélyt a globális vagy közel optimális megoldás megtalálására.

4. A klaszterek számának (K) kiválasztása

A K értékének megválasztása kritikus lépés, mivel meghatározza a klaszterezés minőségét.

4.1. Könyök módszer

- Ábrázoljuk a költségfüggvényt (J) különböző K értékek függvényében.
- Az elbow point (könyökpont) az a K érték, ahol a költség további csökkenése már nem jelents, vagyis a további klaszterek hozzáadása már nem hoz jelents javulást.
- Pé esettanulmány: Ha $K = 3$ -nál a költség jelentsen csökken, de $K = 4$ -nél már alig, akkor $K = 3$ lehet az optimális választás.

4.2. Alkalmazás-specifikus értékelés

- Néha K -t a konkrét alkalmazás alapján választjuk.
- Pé esettanulmány: T-shirt méretek meghatározásakor K -t a méretkategóriák száma (pl. S, M, L) alapján állítjuk be.
- Értékeljük a klaszterezés teljesítményét egy, az alkalmazásra szabott metrika alapján, például hogy mennyire jól illeszkednek a klaszterek a méretosztályozási célhoz.

5. A klaszterezés alkalmazásai

A klaszterezés számos területen alkalmazható, mivel lehetővé teszi az adatok strukturálatlan mintáinak azonosítását. Az alábbi táblázat összefoglalja a fbb alkalmazási területeket:

Alkalmazási terület	Leírás
Piaci szegmentáció	Ügyfelek vagy termékek csoportosítása hasonló jellemzők alapján
Számítógép-klaszterek szervezése	Számítási erőforrások vagy csomópontok hatékony csoportosítása.
Szociális hálózatelemzés	Közösségek vagy csoportok azonosítása szociális hálózatokban.
Csillagászati adatelemzés	Égitestek vagy adatpontok csoportosítása tudományos kutatásokhoz

1. táblázat. Klaszterezés alkalmazási területei

6. A klaszterezési algoritmusok kihívásai és korlátai

A K-means algoritmus nem minden esetben teljesít jól, különösen bizonyos adatstruktúrák esetén.

6.1. Nem elválasztott klaszterek

- Ha a klaszterek nem jól elválasztottak, a K-means nehezen azonosítja ket.
- Pé esettanulmány: T-shirt méretek meghatározása, ahol a méretek átfedhetnek (pl. közepes és nagy méret közötti átmenet).
- Megoldás: Más algoritmusok, például srségalapú klaszterezés (pl. DBSCAN), jobban kezelhetik az ilyen eseteket.

6.2. További korlátok

- **Egyenl méret klaszterek feltételezése:** A K-means hajlamos hasonló méret klasztereket létrehozni, ami nem mindig felel meg a valós adatoknak.
- **Euklideszi távolság használata:** Az algoritmus az euklideszi távolságra támaszkodik, ami nem mindig megfelel más típusú adatokhoz.
- **Érzékenység a kiugró értékekre:** A kiugró adatpontok jelentsen befolyásolhatják a centroidok pozícióját.

7. Összegzés

A klaszterezés, különösen a K-means algoritmus, hatékony eszköz az adatok csoportosítására felügyelet nélküli tanulási környezetben. Az algoritmus egyszer, de erteljes, iteratív módon minimalizálja a klaszteren belüli távolságokat. Az inicializálás, a költségfüggvény optimalizálása és a K értékének megfelel kiválasztása kulcsfontosságú a sikerhez. Az alkalmazások széles skálája, mint a piacssegmentálás vagy a szociális hálózatok elemzése, bizonyítja a klaszterezés gyakorlati hasznát. Azonban a nem elválasztott klaszterek és egyéb korlátok miatt fontos megérteni az algoritmus határait.

Forrás

- Stanford Egyetem ML-005 Eladás 13, Andrew Ng.
- klaszterezés.pptx diasor.