

Vizsgajegyzet: Logisztikus Regresszió

ML-005 Lecture 6 | Stanford University

2025. június 14., 16:17 CEST

Forrás

Diasor („logisztikusregresszio.pptx”) és ML-005 Lecture 6 eladás (01 Classification)

1. Bevezetés

A logisztikus regresszió egy felügyelt tanulási módszer bináris osztályozási problémák megoldására, ahol a kimeneti változó (y) két osztályt jelöl: 0 (negatív osztály) vagy 1 (pozitív osztály). Az osztályozás célja címkék hozzárendelése az adatokhoz, például e-mailek spam/nem spam besorolása vagy daganatok rosszindulatú/jóindulatú osztályozása. A logisztikus regresszió a lineáris regresszióval ellentétben valószínűségeket ad a kimenetre, biztosítva, hogy az eredmény 0 és 1 között legyen.

- **Cél:** Osztályozás, ahol $y \in \{0, 1\}$.
- **Példák:**
 - E-mail: Spam (1) vagy nem spam (0)?
 - Online tranzakció: Csalás (1) vagy nem csalás (0)?
 - Daganat: Rosszindulatú (1) vagy jóindulatú (0)?
- **Jelölések:** 0 = negatív osztály (pl. jóindulatú daganat), 1 = pozitív osztály (pl. rosszindulatú daganat).
- **Kontextus:** A logisztikus regresszió valószínűségeket modellez, nem folytonos értékeket.

2. Osztályozási Probléma

Az osztályozási problémákban a cél egy bemenet (x) alapján eldönteni, hogy melyik osztályba tartozik ($y = 0$ vagy $y = 1$). A lineáris regresszió nem alkalmas erre, mert a kimenete bármilyen valós szám lehet, míg az osztályozáshoz 0 és 1 közötti értékek szükségesek.

- **Példa:** Daganat mérete (x_1) alapján elrejelzés, hogy rosszindulatú-e ($y = 1$) vagy sem ($y = 0$).

- **Küszöb:** A hipotézis kimenete ($h_\theta(x)$) alapján döntés:

$$\begin{cases} h_\theta(x) \geq 0.5 \implies y = 1 \\ h_\theta(x) < 0.5 \implies y = 0 \end{cases}$$

3. Modell Reprezentáció

A logisztikus regresszió a szigmoid függvényt használja, hogy a lineáris kombinációt ($\theta^T x$) 0 és 1 közötti valószínűséggé alakítsa.

- **Hipotézis:**

$$h_\theta(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

ahol $g(z) = \frac{1}{1+e^{-z}}$ a szigmoid (logisztikus) függvény, és $\theta^T x = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_n x_n$, $x_0 = 1$ (bias).

- **Tulajdonságok:**

$$- 0 \leq h_\theta(x) \leq 1.$$

- $h_\theta(x)$ a $P(y = 1 \mid x; \theta)$ valószínűséget jelöli, azaz annak esélyét, hogy $y = 1$ az adott x mellett.

- **Példa:** Ha $x = [1, \text{tumorSize}]^T$, és $h_\theta(x) = 0.7$, akkor 70% az esély, hogy a daganat rosszindulatú ($y = 1$).
- **Valószínűségek:**

$$P(y = 1 \mid x; \theta) = h_\theta(x), \quad P(y = 0 \mid x; \theta) = 1 - h_\theta(x)$$

$$P(y = 0 \mid x; \theta) + P(y = 1 \mid x; \theta) = 1$$

4. Döntési Határ

A döntési határ az a vonal, felület vagy hipersík, amely elválasztja az osztályokat. Az osztályozás attól függ, hogy egy pont melyik oldalán helyezkedik el.

- **Definíció:** A döntési határ ott van, ahol $h_\theta(x) = 0.5$, azaz $\theta^T x = 0$, mivel $g(0) = 0.5$.
- **Lineáris döntési határ:** Ha $\theta = [\theta_0, \theta_1, \theta_2]^T$, akkor $\theta_0 + \theta_1 x_1 + \theta_2 x_2 = 0$ egy egyenes.
- **Példa:** Ha $\theta = [-3, 1, 1]^T$, a döntési határ: $-3 + x_1 + x_2 = 0$, vagyis $x_2 = 3 - x_1$.
- **Nemlineáris döntési határ:** Polinomiális vagy más nemlineáris jellemzőkkel (pl. $x_1^2, x_1 x_2$) komplexebb határok modellezhetők, például kör alakú határ: $\theta_0 + \theta_1 x_1^2 + \theta_2 x_2^2 = 0$.

5. Költségfüggvény

A lineáris regresszió négyzetes hibája nem megfelel logisztikus regresszióhoz, mert nem konvex költségfüggvényt eredményez. Ehelyett a logisztikus regresszió logaritmikus veszteséget használ.

- **Adathalmaz:** $\{(x^{(i)}, y^{(i)})\}_{i=1}^m$, ahol $x^{(i)}$ a bemeneti vektor, $y^{(i)} \in \{0, 1\}$.
- **Egyedi költség:**

$$\text{Cost}(h_\theta(x^{(i)}), y^{(i)}) = \begin{cases} -\log(h_\theta(x^{(i)})) & \text{ha } y^{(i)} = 1 \\ -\log(1 - h_\theta(x^{(i)})) & \text{ha } y^{(i)} = 0 \end{cases}$$

- **Tulajdonságok:**
 - Ha $y = 1$ és $h_\theta(x) \approx 1$, a költség ≈ 0 .
 - Ha $y = 1$ és $h_\theta(x) \rightarrow 0$, a költség $\rightarrow \infty$.
 - Ha $y = 0$ és $h_\theta(x) \approx 0$, a költség ≈ 0 .
 - Ha $y = 0$ és $h_\theta(x) \rightarrow 1$, a költség $\rightarrow \infty$.

- **Összesített költségfüggvény:**

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-y^{(i)} \log(h_\theta(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))]$$

- **Cél:** $J(\theta)$ minimalizálása a θ paraméterek optimális értékének megtalálásához.

6. Gradiens Ereszkedés

A gradiens ereszkedés a költségfüggvény minimalizálására szolgál, hasonlóan a lineáris regresszióhoz, de a szigmoid függvény miatt más a parciális derivált.

- **Frissítési szabály:**

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta), \quad \forall j = 0, \dots, n$$

- **Parciális derivált:**

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

- **Algoritmus:**

$$\text{ismételd, amíg konvergál } \left\{ \theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}, \quad \forall j \right\}$$

- **Megjegyzés:** A frissítési szabály formailag azonos a lineáris regresszióéval, de $h_\theta(x) = g(\theta^T x)$ miatt eltér a számítás.

- **Példa kód (Python):**

```
import numpy as np
def sigmoid(z):
    return 1 / (1 + np.exp(-z))
for iter in range(max_iter):
    predictions = sigmoid(np.dot(X, theta))
    errors = predictions - y
    gradients = (1/m) * np.dot(X.T, errors)
    theta -= alpha * gradients
    J = -(1/m) * np.sum(y * np.log(predictions) + (1-y) * np.log(1-predictions))
    if abs(J_old - J) < epsilon:
        break
```

7. Optimalizálási Algoritmusok

A gradiens ereszkedés mellett fejlettebb optimalizálási algoritmusok is használhatók a költségfüggvény minimalizálására.

- **Cél:** $J(\theta)$ és $\frac{\partial}{\partial \theta_j} J(\theta)$ kiszámítása minden j -re, majd $\min_{\theta} J(\theta)$ megtalálása.
- **Algoritmusok:**
 - Konjugált gradiens.
 - BFGS (Broyden-Fletcher-Goldfarb-Shanno).
 - L-BFGS (Limited-memory BFGS).

- **Példa (Octave/MATLAB):**

```
options = optimset('GradObj', 'on', 'MaxIter', 100);
initialTheta = zeros(n+1, 1);
[optTheta, functionVal, exitFlag] = fminunc(@costFunction, initialTheta, options);
```

- **Elnyök:** Gyorsabb konvergencia, nem kell tanulási rátát (α) manuálisan választani.

8. Többosztályos Osztályozás

A logisztikus regresszió kiterjeszthet többosztályos problémákra az egy mindenki ellen (one-vs-all) módszerrel.

- **Példák:**
 - E-mail mappázás: Munka, Barátok, Család, Hobbi.
 - Orvosi diagnózis: Nincs betegség, Megfázás, Influenza.
 - Idjárás: Napos, Felhs, Ess, Havas.

- **Módszer:** K osztály esetén K bináris osztályozót tanítunk, ahol minden osztályozó az adott osztályt (1) a többitl (0) választja el.
- **Algoritmus:**
 1. Minden $k = 1, \dots, K$ -ra taníts egy logisztikus regressziós modellt, ahol $y = 1$, ha az osztály k , különben $y = 0$.
 2. Predikció: Új x -re számítsd ki az összes $h_{\theta}^{(k)}(x)$ -et, és válaszd a legnagyobb valószínűség osztályt:
$$\arg \max_k h_{\theta}^{(k)}(x)$$
- **Példa:** E-mail mappázás 4 osztályra (Munka, Barátok, Család, Hobbi). Négy modellt tanítunk:
 - $h_{\theta}^{(1)}(x)$: Munka vs. többi.
 - $h_{\theta}^{(2)}(x)$: Barátok vs. többi.
 - $h_{\theta}^{(3)}(x)$: Család vs. többi.
 - $h_{\theta}^{(4)}(x)$: Hobbi vs. többi.

9. Példa Alkalmazás

- **Probléma:** Daganat rosszindulatúságának előrejelzése a mérete alapján.
- **Adatok:** $\{(x^{(i)}, y^{(i)})\}$, pl. $x^{(i)} = [1, \text{tumorSize}]^T$, $y^{(i)} \in \{0, 1\}$.
- **Folyamat:**
 1. Inicializálás: $\theta = [0, 0]^T$, $\alpha = 0.01$.
 2. Sigmoid függvény: $h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$.
 3. Gradiens ereszkedés futtatása a költségfüggvény minimalizálására.
 4. Eredmény: Pl. $\theta = [-3, 1]^T$.
- **Predikció:** Új daganat mérete $x = [1, 5]^T$:

$$h_{\theta}(x) = \frac{1}{1 + e^{-(-3+1 \cdot 5)}} = \frac{1}{1 + e^{-2}} \approx 0.88$$

Mivel $h_{\theta}(x) \geq 0.5$, $y = 1$ (rosszindulatú), 88% valószínűséggel.

10. Kulcsformulák

- **Hipotézis:**

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

- **Költségfüggvény:**

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-y^{(i)} \log(h_{\theta}(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$$

- Gradiens Ereszkedés:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}, \quad \forall j$$